

Segmentacija slika primenom algoritma optimizacije kolonijom mrava

Dragan Mladenović

Matematički fakultet

1. Uvod.....	2
2. Teorijska osnova algoritma optimizacije kolonijom mrava.....	3
3. Ideja rešenja.....	4
1. Inicijalizacija.....	5
2. Kretanje i formiranje putanja mrava.....	5
3. Evaluacija i ažuriranje feromona.....	6
4. Izbor najboljeg segmenta i akumulacija.....	6
5. Region Growing ekspanzija.....	7
6. Rezultat.....	7
4. Poređenje sa Simple BGR algoritmom.....	8
5. Ocenjivanje rezultata.....	10
6. Neki primeri.....	16
7. Zaključak.....	18

1. Uvod

U ovom radu je predstavljena jedna od tehnika za segmentaciju slika pomoću algoritma optimizacije kolonijom mrava. Segmentacija slika je proces particionisanja digitalne slike na više segmenata slike, poznatijih i kao regioni ili objekti slike (skupovi piksela). Cilj segmentacije je pojednostavljivanje ili promena reprezentacije slike u nešto što je smislenije i lakše za analizu. Segmentacija slika se obično koristi da locira objekte i granice (linije, krive, itd.) na slikama. Preciznije, segmentacija slika je proces dodeljivanja oznake svakom pikselu na slici tako da pikseli sa istom oznakom dele određene karakteristike.

Tehnike segmentacije slika mogu se grupisati u nekoliko kategorija, kao što su segmentacija zasnovana na ivicama, segmentacija orijentisana prema regionima, pragovi histograma i algoritmi klasterovanja. Cilj algoritama klasterovanja je agregacija podataka u grupe tako da podaci u svakoj grupi dele slične karakteristike, dok se klasteri podataka razlikuju jedan od drugog. Problematična stvar u segmentaciji slika je otkrivanje objekata koji možda nemaju piksele podataka sa sličnim spektralnim karakteristikama. Stoga, postupak segmentacije slika koji se oslanja samo na spektralne karakteristike slike nije uvek poželjan. Da bi se prevazišao ovaj problem, prostorne informacije, kao i druge spektralne informacije podataka piksela, takođe trebaju biti uzete u obzir.

Postoji niz tehnika razvijenih za optimizaciju, inspirisanih ponašanjem prirodnih sistema i drugih tehnika. Inteligencija jata je predstavljena u literaturi kao tehnika optimizacije. ACO algoritam je prvi put predstavljen i potpuno implementiran na problemu putovanja trgovca (TSP), koji se može formulirati kao pronalaženje najkraćeg zatvorenog puta u datom skupu čvorova koji prolazi kroz svaki čvor jedanput. ACO algoritam na koji se fokusiramo zasniva se na nizu lokalnih poteza sa probablističkom odlukom zasnovanom na parametru, nazvanom feromon, kao vodiču do objektivnog rešenja. Postoje algoritmi koji, iako se oslanjaju na osnovne principe ACO algoritma, ne prate strogo sve njegove karakteristike. Takvi algoritmi se često neformalno nazivaju "algoritmi zasnovani na mravima" ili jednostavno "mravlji algoritmi". Takođe, razvijeni su različiti pristupi zasnovani na mravima za problem klasterovanja podataka.

2. Teorijska osnova algoritma optimizacije kolonijom mrava

Algoritam optimizacije kolonijom mrava (Ant Colony Optimization – ACO) pripada klasi metaheurističkih algoritama inspirisanih prirodnim procesima. Njegova teorijska osnova se zasniva na kolektivnom ponašanju i decentralizovanom rešavanju problema putem komunikacije feromonima. U formalnom smislu, ACO može biti predstavljen kao stohastički proces pretrage grafova, gde čvorovi predstavljaju moguća stanja sistema, a ivice prelaze između stanja.

U kontekstu segmentacije slika, svaki piksel se može posmatrati kao čvor u grafu, dok prelazak između susednih piksela predstavlja kretanje mrava. Cilj je da se otkriju putevi (regioni) koji imaju zajedničke karakteristike, poput sličnosti u intenzitetu, teksturi ili boji.

Ovaj algoritam je inspirisan posmatranjem stvarnog ponašanja mravinjaka u potrazi za hranom i činjenicom da mravi često mogu pronaći najkraći put dok traže hranu. Ovo se postiže deponovanjem i akumulacijom hemijske supstance nazvane feromon koju mrav ostavlja prolazeći ka hrani. Tokom svoje potrage, mrav koristi sopstveno znanje o tome odakle dolazi miris hrane (nazivamo to heurističkom informacijom) i odluku drugih mrava o putanji ka hrani (informacija o feromonima). Nakon što odluči svoj put, potvrđuje ga deponovanjem svog feromona, čime staza feromona postaje gušća i verovatnija za izbor drugih mrava. Ovo je mehanizam učenja koji mravi poseduju pored sopstvenog prepoznavanja puta. Kao rezultat ove konsultacije sa ponašanjem mrava već prikazanim u potrazi za hranom i povratku u gnezdo, obeležava se najbolji put koji je najkraći, od gnezda ka hrani.

Matematički, verovatnoća da mrav k pređe sa piksela i na susedni piksel j data je formulom:

$$P_{ij}^{(k)} = \frac{[\tau_{ij}]^{\alpha} [\eta_{ij}]^{\beta}}{\sum_{l \in N_i} [\tau_{il}]^{\alpha} [\eta_{il}]^{\beta}}$$

gde je:

- τ_{ij} - količina feromona na prelazu $i \rightarrow j$,

- η_{ij} - heuristička informacija (npr. inverzna razlika intenziteta),
- α i β – parametri koji određuju relativni uticaj feromona i heuristike,
- N_i – skup susednih piksela čvora i .

3. Ideja rešenja

Implementacija algoritma je realizovana u Python programskom jeziku koristeći biblioteke *NumPy* i *OpenCV*. Slika se učitava kao niz piksela, a svaki piksel se tretira kao potencijalni deo putanje mrava.

Glavne komponente implementacije uključuju:

- **Inicijalizaciju parametara:** broj mrava, broj iteracija, parametri α, β, ρ ;
- **Definisanje heuristike:** heuristička informacija se zasniva na razlici intenziteta između susednih piksela – pikseli sličnih vrednosti imaju veću verovatnoću da budu povezani;
- **Feromonska matrica:** inicijalno uniformna, dinamički se ažurira nakon svake iteracije;
- **Konstrukcija putanja:** mravi nasumično biraju početne pozicije i grade put kroz piksele sa najvećom kombinovanom verovatnoćom;
- **Ažuriranje feromona:** primenjuje se lokalno i globalno ažuriranje;
- **Region Growing faza (proširenje regiona):** nakon završetka iteracija, najstabilniji delovi putanja mrava se koriste kao početne pozicije za rast regiona. Na ovaj način, početne tačke dobijene mravljim algoritmom se šire u kompletne vodene površine.

Vizuelizacija rezultata je urađena prikazivanjem binarne maske segmentisanih delova slike, gde se vodene površine prikazuju belom bojom, a ostali delovi crnom.

Glavni delovi algoritma:

1. Inicijalizacija

Ulaz je kolor slika u BGR formatu.

Na početku se inicijalizuju:

- broj mrava `num_ants`,
- broj iteracija `max_iterations`,
- parametri ACO modela:
 - α (`alpha`) – značaj feromona (koliko mravi slede već postojeće tragove),
 - β (`beta`) – značaj vizuelne privlačnosti piksela (koliko odluke zavise od boje),
 - ρ (`rho`) – stopa isparavanja feromona.

Pored toga, kreira se matrica feromona iste veličine kao slika, inicijalno popunjena jedinicama.

2. Kretanje i formiranje putanja mrava

Svaki mrav započinje kretanje sa slučajno izabranog piksela slike.

Kretanje se odvija iterativno:

1. Za trenutni položaj (r , c) pronalaze se susedi.
2. Za svakog suseda računa se verovatnoća prelaska:
3. Sledeći piksel se bira nasumično prema distribuciji P_{ij} .
4. Ako izabrani piksel ispunjava uslov da predstavlja vodenu površinu, mrav nastavlja kretanje; u suprotnom, broji se broj “neuspešnih” koraka.

Ukoliko mrav više puta uzastopno ne pronađe vodeni piksel, aktivira se mehanizam povratka (backtracking) koji omogućava da se vrati nekoliko koraka unazad i pokuša drugim putem, čime se povećava verovatnoća pronalaženja većeg segmenta.

3. Evaluacija i ažuriranje feromona

Po završetku kretanja svakog mrava, računa se njegova “ocena” ($score$) – broj piksela na njegovom putu koji su prepoznati kao vodeni.

Nakon svake iteracije, feromon se ažurira po formuli:

$$\tau_{ij} \leftarrow (1 - \rho)\tau_{ij} + \sum_k \Delta\tau_{ij}^{(k)}$$

gde je ρ stopa isparavanja, a $\Delta\tau_{ij}^{(k)}$ količina feromona koju je ostavio mrav k , proporcionalna kvalitetu rešenja.

Na taj način se pojačavaju feromoni na putanjama koje su prošli uspešni mravi, čime sledeće generacije imaju veću šansu da se kreću tim pravcem.

4. Izbor najboljeg segmenta i akumulacija

U svakoj iteraciji se bira mrav sa najvećim $score$ i njegovi pikseli se označavaju u maski segmentacije.

Kroz više iteracija, ove maske se akumuliraju, stvarajući sve potpuniji prikaz segmenta koji pripada vodi.

5. Region Growing ekspanzija

Nakon završetka ACO faze, pronađeni segmenti se šire i povezuju pomoću region growing (ekspanzija regiona) algoritma.

Početni pozicije čine pikseli koji su deo najboljih putanja, a zatim se region širi na susede koji zadovoljavaju funkciju atraktivnosti.

Ovaj korak omogućava spajanje više manjih putanja u jedan koherentan vodeni segment.

6. Rezultat

Konačni rezultat algoritma je **binarna maska** veličine ulazne slike gde:

- vrednost 255 označava piksele koji pripadaju vodi,
- vrednost 0 označava ostale površine (zemlja, vegetacija, objekti).

Ova maska može dalje da se koristi za:

- računanje površine vode,
- praćenje promena vodostaja
- ili kao ulaz za klasifikacione i GIS analize.

4. Poređenje sa Simple BGR algoritmom


Simple BGR algoritam za segmentaciju vodenih površina predstavlja jednostavan pristup koji se zasniva isključivo na analiziranju intenziteta boje u RGB prostoru. Svakom pikselu se dodeljuje oznaka vode ako njegove vrednosti crvenog, zelenog i plavog kanala zadovoljavaju određene pragove koji su karakteristični za boju vode na datim slikama. Ovaj pristup ne koristi nikakve prostorne informacije, već klasifikuje piksele pojedinačno, bez uvažavanja njihovog položaja ili veze sa susedima. Kao rezultat, algoritam je izuzetno brz i jednostavan za implementaciju, ali može dovesti do fragmentiranih i nestabilnih maski, naročito u slučajevima kada su vodene površine delimično prekrivene senkama, refleksijama ili se tonovi tla i vode preklapaju.

Za razliku od toga, algoritam optimizacije kolonijom mrava (ACO) koristi isti princip prepoznavanja piksela vode, ali kombinuje taj proces u prostorno-koherentnu optimizaciju. Mravi se nasumično kreću kroz sliku i grade putanje koje povezuju piksele sličnih karakteristika, pri čemu feromoni predstavljaju kolektivno pamćenje sistema. Na taj način se ne posmatraju pojedinačni pikseli, već se prepoznaju povezane regije koje verovatno pripadaju istom objektu — u ovom slučaju, vodenoj površini. Mravlji algoritam tokom iteracija uči koje oblasti slike su stabilne i verovatne kao deo vode, dok se manje verovatne putanje postepeno napuštaju isparavanjem feromona.

Iako je ACO pristup računarski zahtevniji i sporiji od simple BGR algoritma, njegova glavna prednost je sposobnost da generiše koherentne i povezane segmente čak i kada je boja vode neujednačena. Simple BGR algoritam može uspešno identifikovati osnovne vodene oblasti, ali bez globalne povezanosti i otpornosti na šum, dok ACO metod koristi interakciju između mrava da bi pronašao celovite segmente vodenih površina koji bolje odgovaraju stvarnim granicama poplavljenih područja. U tom smislu, ACO pristup ne poboljšava samo tačnost segmentacije, već i stabilnost rezultata kroz iterativno učenje i prostornu saradnju mrava.



ACO algoritam:



Simple BGR algoritam:





ACO algoritam:



Simple BGR algoritam:



5. Ocenjivanje rezultata

Za ocenjivanje uspešnosti primenjenih algoritama korišćene su dostupne referentne maske poplavljenih područja, koje omogućavaju kvantitativno poređenje između predviđenih i stvarnih regiona vode.

Evaluacija je sprovedena pomoću sledećih metrika — **Intersection over Union (IoU)**, **Precision**, **Recall** i **Dice koeficijenta**.

- **Jaccard indeks (Intersection over Union – IoU):** meri sličnost između predviđene segmentacije i ručno označenih maski.

$$IoJ = \frac{|A \cap B|}{|A \cup B|}$$

gde su A – skup piksela predviđenih kao voda, B – skup stvarnih piksela vode.

- **Preciznost (Precision) i odziv (Recall):**

$$Precision = \frac{TP}{TP + FP}, Recall = \frac{TP}{TP + FN}$$

gde su *TP* – tačno detektovani vodeni pikseli, *FP* – pogrešno detektovani, *FN* – propušteni.

Precision pokazuje koliki procenat piksela koji su označeni kao voda zaista pripada vodenom području (meri tačnost detekcije).

Recall pokazuje koliki procenat stvarnih vodenih piksela je uspešno detektovan (meri potpunost detekcije).

- **F1-score(Dice koeficijent):**

F1-Score je harmonička sredina Preciznosti i Odziva. On daje jedinstvenu meru performansi modela, uzimajući u obzir i lažno Pozitivne (FP) i lažno Negativne (FN) rezultate. Posebno je koristan kada su klase nebalansirane.

Formula F1-Score-a:

$$\text{F1-Score} = \frac{2 \cdot \text{TP}}{2 \cdot \text{TP} + \text{FP} + \text{FN}}$$

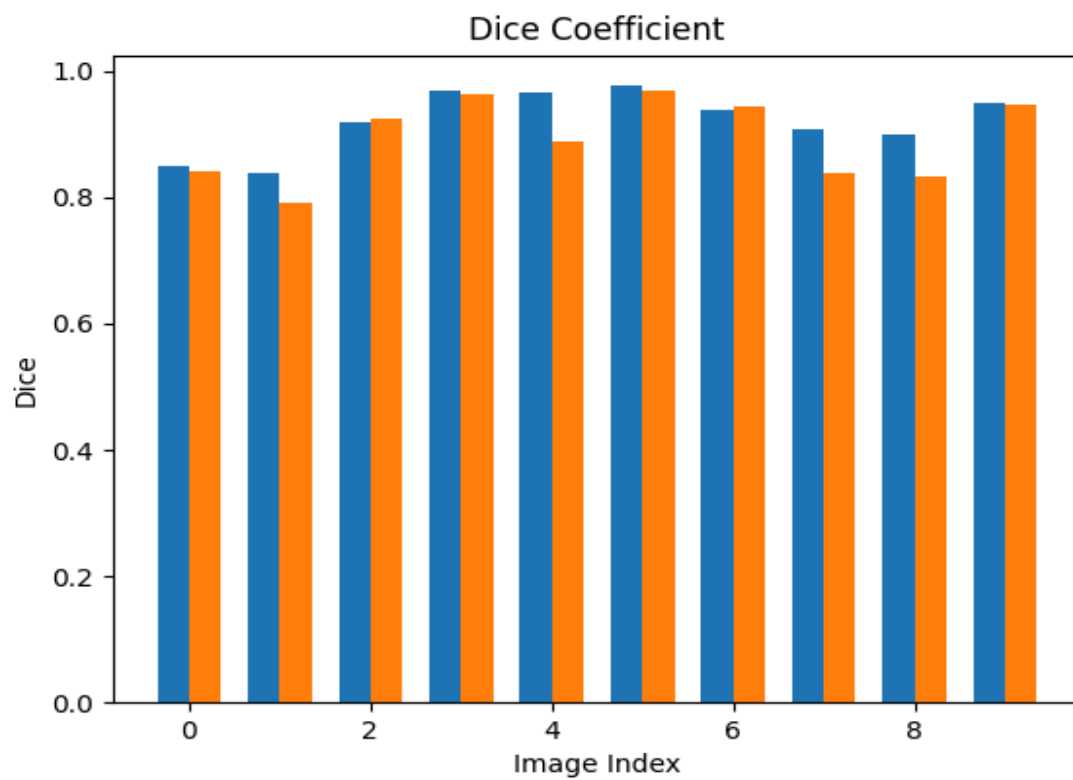
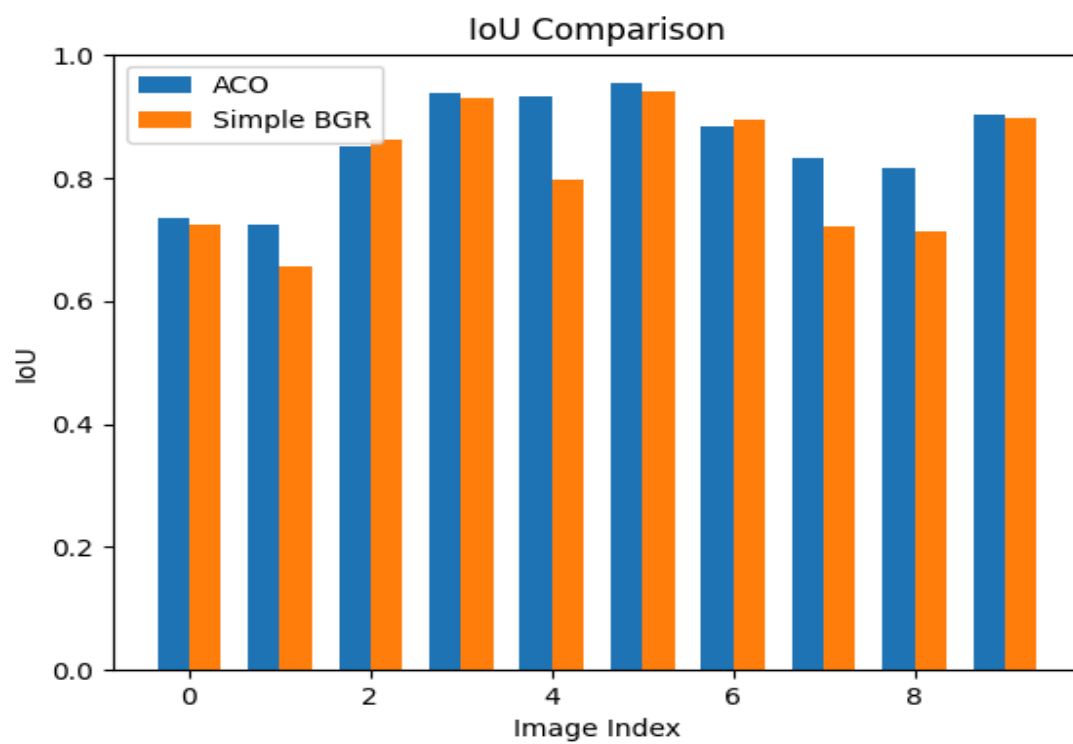
Povezanost s Dice Koeficijentom:

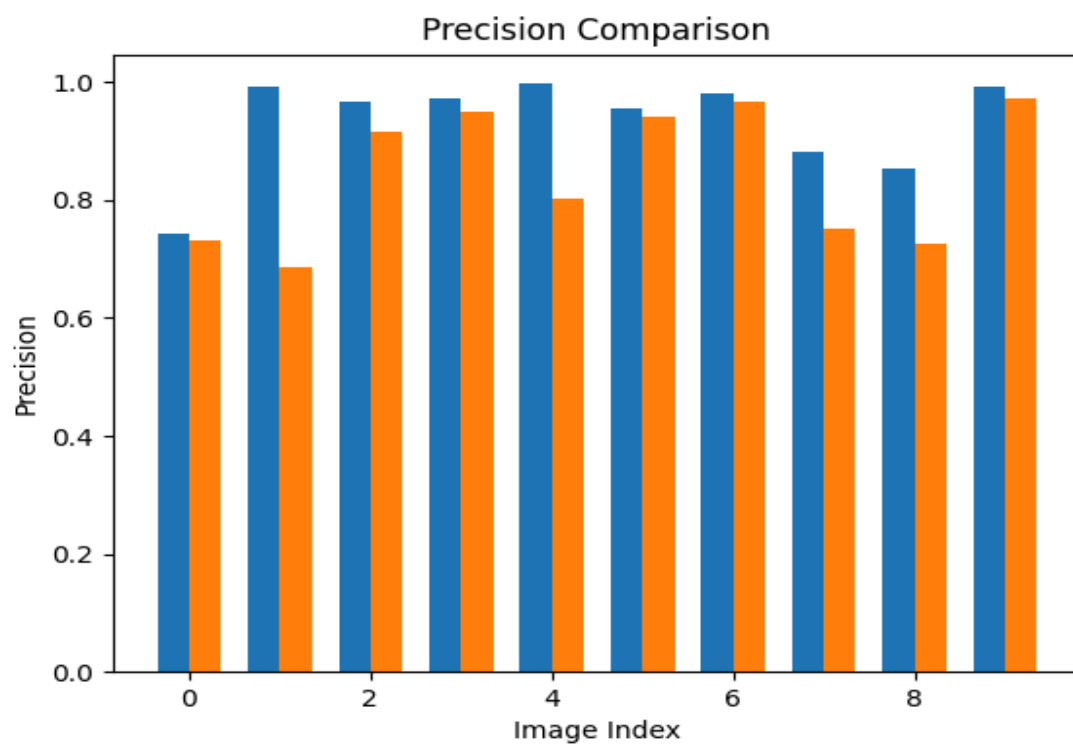
U kontekstu segmentacije, F1-Score je matematički identičan Dice koeficijentu (Dice Loss/Coefficient), koji se često koristi kao funkcija gubitka ili metrika.

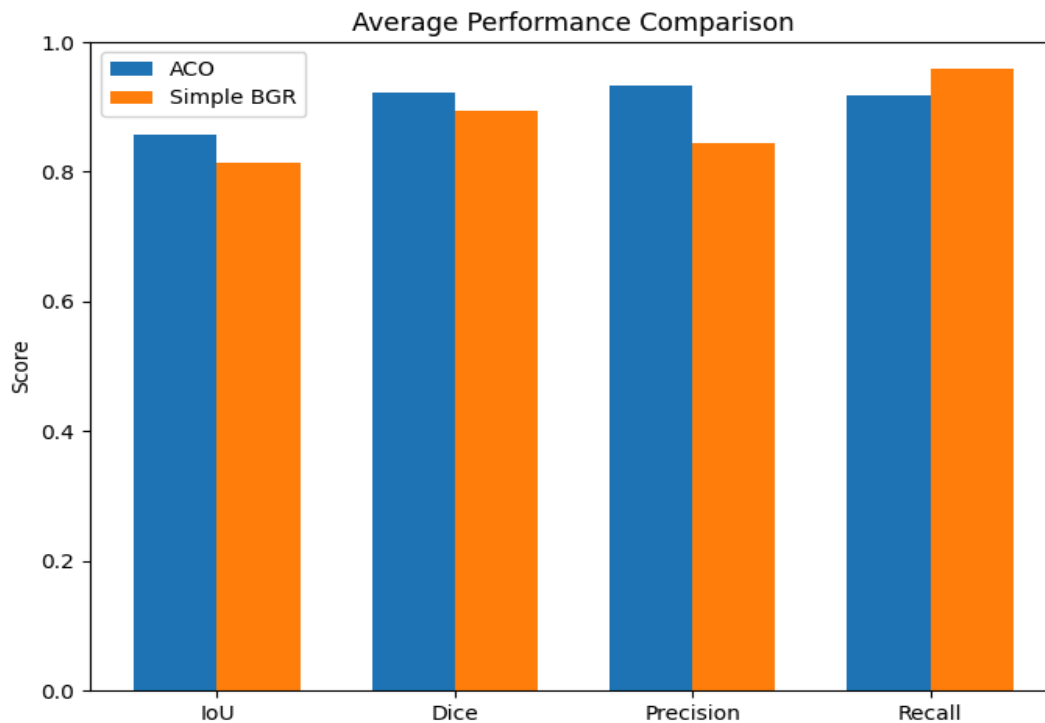
$$\text{Dice} = \frac{2 \cdot |A \cap B|}{|A| + |B|}$$

gdje je $|A \cap B|$ (presek) ekvivalentan **TP**, a $|A| + |B|$ ekvivalentan **TP+FP+TP+FN** (tj. $2 \cdot \text{TP} + \text{FP} + \text{FN}$).

U eksperimentalnim testovima ACO algoritam pokazao je uglavnom bolje rezultate u odnosu na Simple BGR algoritam u svim evalucionim metrikama osim recall metrike. Dobijene vrednosti za ACO algoritam iznose IoU u opsegu od 0.738 do 0.954, Dice koeficijent između 0.90 i 0.94, Precision između 0.74 i 0.97, i Recall između 0.84 i 0.98, što ukazuje na visoku poklapanost sa referentnim maskama i uspešnu detekciju vodenih površina.







Ovi rezultati pokazuju da ACO algoritam preciznije prepoznaje vodene površine, posebno u područjima gde su granice nejasne, senke prisutne ili tonovi vode delimično izmenjeni refleksijom okoline. Zahvaljujući mehanizmu feromona i heurističkom vođenju mrava, algoritam uspešno povezuje prostorno bliske i spektralno slične piksele u koherentne regije.


Prednost ACO algoritma ogleda se u njegovoj sposobnosti da poveže neujednačene i delimično prekrivene oblasti vode, zahvaljujući načinu kretanja i međusobnom prenošenju informacija između mrava.

S druge strane, Simple BGR algoritam daje dobre rezultate u scenama sa jasnim kontrastom između vode i kopna, ali ima ograničenja kod složenijih slučajeva, jer se u potpunosti oslanja na statičke pragove komponenti boje.

Može se reći da ACO pristup generalno daje robusnije i tačnije rezultate u detekciji vodenih površina, naročito kada su u pitanju slike sa promenljivim osvetljenjem i niskim kontrastom između klasa.

6.Neki primeri





7. Zaključak

U ovom radu prikazana je primena algoritma optimizacije kolonijom mrava za segmentaciju slika poplavljenih područja. ACO pristup, zahvaljujući probabilističkom pretraživanju i feromonskoj komunikaciji, omogućava otkrivanje homogenih regiona vode čak i u uslovima slabog kontrasta i neujednacenog osvetljenja.

Uvođenjem dodatne faze *region growing* algoritam dodatno proširuje i stabilizuje segmentisane površine, čime se postižu povezani i realniji regioni vodenih tela.

U poređenju sa klasičnim metodama segmentacije (Simple BGR), mravlji algoritam pokazuje bolje rezultate u tačnosti i konzistentnosti segmentacije, naročito na kompleksnim slikama gde prisustvo senki, refleksija ili vegetacije otežava izdvajanje vodenih površina.

Rezultati evaluacije pokazuju da ACO pristup generalno daje veće vrednosti metrika kao što su IoU, Precision i Dice koeficijent, dok su vrednosti Recall-a nešto niže, što ukazuje na konzervativniji, ali precizniji pristup detekciji vodenih piksela.

Iako ACO metod nudi značajno poboljšanje u kvalitetu segmentacije, njegovo glavno ograničenje je veća računarska složenost i duže vreme izvršavanja u poređenju sa jednostavnim metodama zasnovanim na boji.

Moguća poboljšanja uključuju:

- **paralelizaciju algoritma** (npr. korišćenjem GPU-a ili više niti),
- **adaptivno podešavanje parametara** feromona i heuristike tokom iteracija,
- **kombinovanje ACO pristupa sa metodama mašinskog učenja** (npr. CNN karakteristikama) za pametnije vođenje mrava,
- **automatsko određivanje početnih pozicija** u fazi *region growing*.

Dalji pravci istraživanja mogu uključiti primenu hibridnih ACO modela u kombinaciji sa drugim metaheuristikama (npr. PSO ili GA), kao i testiranje algoritma na multispektralnim i satelitskim slikama visoke rezolucije, čime bi se dodatno potvrdila njegova efikasnost u realnim uslovima.

Literatura

1. Image Segmentation Technology Based on Ant Colony Algorithm

https://www.researchgate.net/publication/380621759_Image_Segmentation_Technology_Based_on_Ant_Colony_Algorithm

2. Multi-strategy ant colony optimization for multi-level image segmentation

<https://www.sciencedirect.com/science/article/abs/pii/S1746809423000800>

3. Ant Colony Optimization for Image Segmentation

https://www.researchgate.net/publication/221910624_Ant_Colony_Optimization_for_Image_Segmentation

4. Ant Colony Optimization towards Image Processing

https://indjst.org/download-article.php?Article_Unique_Id=INDJST11466&Full_Text_Pdf_Download=True

5. Self-Regulated Artificial Ant Colonies on Digital Image Habitats

<https://arxiv.org/abs/cs/0512004>

